

基于 MCA 残差学习与条件隐式表示的稀疏 HRTF 插值方法

Young

审阅稿, 2026 年 9 月 7 日

摘要: 针对稀疏头相关传输函数 (HRTF) 插值问题, 本文提出一种基于 MCA 残差学习与条件隐式表示的稀疏 HRTF 插值方法 (FSC)。其中, MCA 表示幅度校正与时间对齐插值 (Magnitude-Corrected and Time-Aligned Interpolation)。FSC 不直接回归完整 HRTF, 而是在 MCA 重建结果上学习附加幅度残差: 稀疏双耳空间观测首先经条件编码器压缩为被试级嵌入表示, 并通过 FiLM 调制 SIREN 连续方向-频率残差场; 双耳频谱 CNN 进一步细化跨频率与双耳结构, 最终复用 MCA 相位完成 HRIR 重建。本文将听觉尺度的 ERB 误差作为核心评价维度, 并在训练中设置 ERB 代理目标以使优化方向与最终评价尽量一致。在 SONICOM 数据集 44 名测试被试的 Q26 协议下, FSC 的全域 ERB、对侧 25° ERB、频带 ILD、ITD 加权 MAE 及全域 LSD 分别为 0.8175、1.2004、1.6205 dB、18.0457 μ s 和 3.5729 dB。相对 MCA, FSC 在前三项幅度 / 声级指标及全域 LSD 上均取得更低均值; 相对学习式方法, FSC 在 ERB、频带 ILD 和 ITD 加权 MAE 上具有较低均值, 而 FSP-AE 和 RANF 在全域 LSD 上更优。进一步的 matched-density 稀疏度实验分别训练 Q14、Q26 和 Q50 模型, 并在 44 名测试被试的共同 743 个未观测方向上评价; 全域 ERB 由 0.9340 降至 0.8132 和 0.7702 dB, 对侧 25° ERB 由 0.9136 降至 0.8378 和 0.7970 dB。结果表明, 基于 MCA 的被试条件残差学习能够有效改善稀疏 HRTF 的幅度与局部频谱重建, 但时间线索、跨数据库泛化和感知收益仍需进一步验证。

关键词: 头相关传输函数; HRTF 插值; MCA; 残差学习; 条件隐式表示; 耳间线索

1 引言

头相关传输函数 (Head-Related Transfer Function, HRTF) 描述声源到双耳鼓膜之间的方向相关声学传递特性, 是双耳空间音频渲染的基础。其时域形式为头相关冲激响应 (Head-Related Impulse Response, HRIR), 包含耳间时间差 (ITD)、耳间声级差 (ILD) 以及由耳廓、头部和躯干产生的单耳频谱线索 [1]。由于个体形态差异显著, 直接使用非个性化 HRTF 可能造成双耳线索失配并降低空间感知性能。高密度个体 HRTF 通常需要在受控声学环境中逐方向测量, 采集成本较高, 因此利用少量测量方向插值得到密集 HRTF 成为降低个性化测量负担的重要途径 [2]。

稀疏 HRTF 插值旨在由有限观测方向估计未测方向的双耳响应。现有方法大致可分为邻近方向加权、函数模型和学习式方法 [3]。前两类方法包括线性 / 双线性插值、矢量基幅值平移 (VBAP)、反距离加权 (IDW)、主成分分析、滤波器模型以及球谐展开 (SH) 等 [4, 5]; 学习式方法则通过自编码器、神经场等结构从稀疏观测中推断目标方向的 HRTF [6, 7]。传统方法具有清晰的物理或几何解释, 而学习式方法具备更强的非线性表示能力。二者共同面临的难点是: 对侧高频响应随方向变化较快, 局部谱峰 / 谱凹口及双耳线索往往比整体低频幅度更难恢复。

时间对齐可以在插值前去除随方向变化的传播时延, 从而降低相位快速变化带来的建模难度 [5]。幅度校正与时间对齐插值 (Magnitude-Corrected and Time-Aligned Interpolation, MCA) 进一步利用频率平滑的幅度表示构造校正滤波器, 在传统插值链路中同时处理时延和幅度误差 [8]。然而, MCA 仍会保留方向相关的剩余幅度误差, 尤其集中于对侧高频和局部频谱结构。与直接从稀疏输入重建完整复数 HRTF 相比, 在 MCA 结果上学习残差可以保留已有插值链路的相位与低频结构, 并将学习目标集中于传统方法尚未消除的误差。

基于这一思路, 本文提出基于 MCA 残差学习与条件隐式表示的 FSC 插值模型。模型由三个协同模块组成: 首先, 稀疏双耳空间观测经条件编码器压缩为被试级 embedding 特

征, 特征级线性调制 (Feature-wise Linear Modulation, FiLM) [9] 据此生成各层调制参数; 随后, 正弦表示网络 (Sinusoidal Representation Network, SIREN) [10] 以方向、频率和 MCA 幅度为坐标建立连续残差场; 最后, 双耳频谱卷积网络联合处理左右耳整谱, 对跨频率局部结构和双耳关系进行进一步细化。模型仅预测 MCA 幅度残差, 重建阶段沿用 MCA 相位及未预测频点, 从而保持信号处理基线和学习模块之间的明确接口。

本文的主要工作如下: (1) 提出一种基于 MCA 残差学习与条件隐式表示的稀疏 HRTF 插值框架, 将学习目标由“直接重建完整 HRTF”转化为“MCA 后的幅度残差补偿”, 在保留传统插值与重建链路的同时聚焦其剩余误差; (2) 将每个被试的稀疏空间双耳观测压缩为固定维度的被试级 embedding, 并利用 FiLM 以该嵌入调制 SIREN 连续残差场, 再结合双耳频谱 CNN 完成跨频率细化; (3) 以 ERB 听觉频带误差作为正文核心评价维度, 在训练中引入 ERB 代理目标, 并以严格 HRIR 域 ERB 评价检验最终重建; (4) 在统一 Q26 测试协议下与传统及学习式方法比较, 并通过 Q14/Q26/Q50 独立训练的 matched-density 实验验证模型随观测方向数量变化的行为。实验结果显示, FSC 的主要收益集中于 ERB 和频带 ILD 等幅度 / 声级指标, 而 ITD 及全域 LSD 相对不同外部方法仍存在取舍。

2 相关工作

2.1 传统 HRTF 插值

球谐展开和邻近方向加权是稀疏 HRTF 插值中常用的传统路线。时间对齐能够降低球谐表示对空间阶数的需求 [5]; SupDEq 通过插值前的方向均衡与插值后的逆均衡改善空间重建, 并进一步研究了不同球面采样方案的影响 [4, 11]。MCA 则在时间对齐插值基础上, 以平滑幅度的插值结果为参考构造幅度校正滤波器 [8]。本文不将这些传统方法视为需要完全替代的基线, 而是将 MCA 作为可解释的初始重建, 并专门学习其剩余幅度误差。

2.2 学习式 HRTF 插值

HRTF 个性化既可以依赖人体形态信息, 也可以依赖稀疏声学测量, 两类任务所提供的个体信息并不相同 [3, 12]。本文关注后者, 即目标个体已具有少量实测 HRTF 的稀疏插值问题。FSP-AE 将正则化线性回归解释为自编码器, 并利用声源方向、频率和输入类型共同处理幅度与 ITD[6]; RANF 结合检索 HRTF、卷积和双向序列建模, 并可在目标个体上进行参数适配 [7]。与这些直接预测目标表示的方法不同, FSC 以前置 MCA 重建为参照, 仅学习附加幅度残差, ITD 则由复用 MCA 相位后的完整 HRIR 重建间接决定。由于不同方法在个体适配、相位恢复和输出表示上存在差异, 本文统一评价其最终重建结果, 而不将原论文分数与本项目重评价结果直接混排。

2.3 条件隐式表示与频谱建模

FiLM 通过条件生成的逐特征缩放和平移对中间特征进行调制 [9], SIREN 则利用周期激活表示连续信号及其高频细节 [10]。本文将二者用于“个体条件下的方向-频率残差场”, 并在其后增加双耳频谱 CNN, 以显式利用邻近频点和左右耳联合信息。本文的贡献不在于首次提出 FiLM、SIREN 或卷积频谱建模, 而在于它们与 MCA 残差接口、双耳频谱细化及分阶段优化的组合。与此同时, 空间音频中的客观误差与主观感知并非一一对应 [13], 因此本文分别报告频谱、ILD 和 ITD 结果, 不将单一指标下降直接解释为定位或外化感改善。

3 MCA 残差学习与条件隐式表示方法

3.1 整体框架与学习目标

本研究以幅度校正与时间对齐插值（Magnitude-Corrected and Time-Aligned Interpolation, MCA）为基础，学习其插值结果中尚未消除的 HRTF 幅度残差。MCA 在时间对齐插值之外引入基于频率平滑表示的幅度校正 [8]。本文将这一传统重建结果保留为基线，利用稀疏观测提供的个体信息预测附加残差，而非直接回归完整复数 HRTF。所用模型简称 FSC，其核心是以被试级条件嵌入调制连续 MCA 残差场，并由 FiLM 条件调制、SIREN 隐式残差表示和 CNN 双耳频谱细化三个模块构成一体化网络。三者在同一前向链路中依次完成个体条件生成、逐方向逐频率残差表示和跨频率双耳校正；分阶段优化仅是训练策略，不改变完整模型由三个模块共同组成的定义。

记被试为 s ，查询方向单位向量为 $\mathbf{q} = (x, y, z)$ ，耳侧为 $e \in \{L, R\}$ ，频率为 f 。被试的 Q 个观测方向构成集合 $\mathcal{O}_s$ 。设参考幅度和 MCA 幅度的 dB 表示分别为 $M_{s,e}^*(\mathbf{q}, f)$ 与 $M_{s,e}^{\text{MCA}}(\mathbf{q}, f)$ ，监督目标定义为

$$r_{s,e}^* = M_{s,e}^* - M_{s,e}^{\text{MCA}}, \quad \hat{r}_{s,e}^* = \frac{r_{s,e}^* - \mu_r}{\sigma_r}. \quad (1)$$

其中 μ_r, σ_r 仅由训练集统计量确定。观测参考幅度只在 $\mathcal{O}_s$ 内作为条件输入，非观测方向的参考幅度用于训练监督或既有评价，不作为推断输入。MCA 幅度及其原有幅度校正特征也只由对应的稀疏观测构造。

【待修改：当前结构图仍含工程阶段命名（如“Hybrid E190”）且信息密度较高，投稿前建议重绘为与正文“FSC”一致的简化结构图。】

围绕上述统一前向链路，下面按信息流顺序说明 FiLM、SIREN 和 CNN 三个模块的具体结构。三个模块共同产生 FSC 的最终残差，而不是彼此独立的候选模型。

3.2 个体条件与连续残差表示

FiLM 模块首先把一个被试的稀疏空间双耳观测集合压缩为固定维度 embedding，并据此调制 SIREN 的各个正弦层。条件编码器对每个观测方向的归一化双耳频谱使用两层一维卷积，拼接该方向的 $\mathbf{q}$ 并投影为 128 维特征；随后按有效方向掩码求均值，再线性映射为被试级条件向量 $\mathbf{z}_s \in \mathbb{R}^{128}$ 。因此，不同被试的空间双耳特征被统一编码到同一 128 维条件空间中，训练阶段可在共享 SIREN 参数的同时利用 $\mathbf{z}_s$ 表达个体差异；该集合编码也避免把未观测方向的参考幅度作为输入。

FiLM 模块借鉴逐特征线性调制（Feature-wise Linear Modulation, FiLM）的条件控制思想 [9]，由共享调制器根据 $\mathbf{z}_s$ 为第 ℓ 个 SIREN 层生成频率缩放、相位偏移和幅度缩放参数：

$$\gamma_\ell = 1 + 0.5 \tanh(\mathbf{g}_\ell), \quad \beta_\ell = \pi \tanh(\mathbf{b}'_\ell), \quad \mathbf{a}_\ell = 1 + 0.5 \tanh(\mathbf{a}'_\ell). \quad (2)$$

其中 $\mathbf{g}_\ell, \mathbf{b}'_\ell, \mathbf{a}'_\ell$ 由 $\mathbf{z}_s$ 经共享隐层和逐层输出头生成。调制作用于全部正弦层，使同一查询坐标在不同被试条件下获得不同的残差表示。上述调制边界及全层配置属于本项目的具体实现，并非对 FiLM 原始公式的直接照搬。

SIREN 模块负责表示方向和频率连续变化的 MCA 幅度残差。查询输入为七维向量

$$\mathbf{u}_{s,\mathbf{q},f} = [x, y, z, \nu_{\text{lin}}(f), \nu_{\text{ERB}}(f), \widetilde{M}_{s,L}^{\text{MCA}}, \widetilde{M}_{s,R}^{\text{MCA}}]^\top. \quad (3)$$

Hybrid E190 模型结构图

FiLM-SIREN + Spectral CNN architecture




图 1: FSC 整体结构。FiLM-SIREN 基础场根据稀疏双耳观测、查询方向与 MCA 幅度生成初始残差；双耳频谱 CNN 进一步结合 MCA 校正特征和跨频率双耳信息输出增量残差。正式模型对三个 E190 成员的 dB 残差等权平均。

Fig. 1: Overall FSC architecture. The FiLM-SIREN base field predicts an initial residual from sparse binaural observations, query direction, and MCA magnitude; the binaural spectral CNN further refines the residual using MCA correction features and cross-frequency binaural information. The final model averages the dB residuals of three E190 members.

这里 ν_{lin} 和 ν_{ERB} 分别将线性频率及等效矩形带宽 (Equivalent Rectangular Bandwidth, ERB) 频率坐标映射至 $[-1, 1]$; 波浪号 MCA 幅度采用独立的训练集均值和标准差归一化。FiLM 提供的全局个体条件与查询位置的局部 MCA 幅度由此通过不同入口共同控制残差预测。

本模块采用正弦表示网络 (Sinusoidal Representation Network, SIREN) 的周期激活形式 [10]。具体实现包含六个正弦层, 每层 256 个隐单元, 并使用 FiLM 模块生成的参数调制各层:

$$\mathbf{h}_\ell = \mathbf{a}_\ell(\mathbf{z}_s) \odot \sin[\omega_\ell \gamma_\ell(\mathbf{z}_s) \odot (\mathbf{W}_\ell \mathbf{h}_{\ell-1} + \mathbf{b}_\ell) + \beta_\ell(\mathbf{z}_s)]. \quad (4)$$

其中 $\mathbf{h}_0 = \mathbf{u}$, $\odot$ 为逐元素乘法, 所有 $\omega_\ell = 20$ 。末端线性层输出左右耳的初始归一化残差 $\tilde{\mathbf{r}}_F = F_\phi(\mathbf{u}, \mathbf{z}_s)$, 并作为 CNN 模块的整谱输入之一。SIREN 的连续坐标表示负责建立跨方向和频率的残差函数, CNN 则在其输出上进一步建模局部频谱与双耳关系。

3.3 双耳频谱细化

CNN 模块在每个查询方向上联合处理左右耳的完整目标频带。输入矩阵 $X_s(\mathbf{q}) \in \mathbb{R}^{7 \times F}$ 依次包含左耳 MCA 幅度、左耳 MCA 幅度校正特征、左耳 FiLM 调制 SIREN 残差、右耳对应的三项, 以及归一化对数频率。MCA 幅度校正特征记为 $\tilde{C}^{\text{MCA}}$, 与网络学习的新残差增量并非同一变量。输入顺序为

$$X_s(\mathbf{q}) = [\tilde{M}_L^{\text{MCA}}, \tilde{C}_L^{\text{MCA}}, \tilde{r}_{F,L}, \tilde{M}_R^{\text{MCA}}, \tilde{C}_R^{\text{MCA}}, \tilde{r}_{F,R}, \nu_{\log}]^\top. \quad (5)$$

式中每项均是长度为 F 的频率序列。 $\nu_{\log}$ 服务于 CNN 输入, 不替代 SIREN 模块的线性 / ERB 双频率坐标。

双耳频谱卷积神经网络 (Convolutional Neural Network, CNN) 首先将七通道输入映射至 48 通道, 再经过四个扩张深度卷积残差块。卷积核长度为 7, 扩张率依次为 1, 2, 4, 8; 块内通过逐点卷积将通道扩展至 96, 再投影回 48, 结合组归一化和 SiLU 激活。方向向量 $\mathbf{q}$ 经两层 64 维映射后, 为各块提供特征缩放与平移。末端 1×1 卷积输出左右耳的频谱增量 $\Delta \tilde{\mathbf{r}}_\theta$ 。该模块显式利用相邻频点和双耳频谱信息, 与 FiLM 和 SIREN 模块共同得到最终残差; 其独立效果仍需与训练目标及优化预算的作用区分。

3.4 训练目标与重建流程

单成员预测及其 dB 转换为

$$\tilde{\mathbf{r}}_H = \tilde{\mathbf{r}}_F + C_\theta(X_s(\mathbf{q}), \mathbf{q}), \quad \mathbf{r}_H^{\text{dB}} = \sigma_r \tilde{\mathbf{r}}_H + \mu_r. \quad (6)$$

因此 CNN 模块增量的 dB 值为 $\sigma_r \Delta \tilde{\mathbf{r}}_\theta$, 不重复加上 μ_r 。正式模型采用三个成员的等权平均:

$$\bar{\mathbf{r}}_H^{\text{dB}} = \frac{1}{3} \sum_{k=1}^3 \mathbf{r}_{H,k}^{\text{dB}}, \quad \hat{\mathbf{M}} = \mathbf{M}^{\text{MCA}} + \bar{\mathbf{r}}_H^{\text{dB}}. \quad (7)$$

权重不根据测试表现重设, 均值在 dB 残差域计算, 而非在线性幅度域计算。

为恢复时域头相关脉冲响应 (Head-Related Impulse Response, HRIR), 在选定频点采用 $10^{\hat{\mathbf{M}}/20}$ 和对应 MCA 相位构造复数频谱, 其余频点直接沿用 MCA 复数值。经共轭对称扩展、1024 点逆快速傅里叶变换 (Inverse Fast Fourier Transform, IFFT) 后, 保留前 256 点 HRIR。模型不学习相位, 所有基于 HRIR 的双耳线索评价必须经过这一完整重建链路。

FSC 在推断时始终使用 FiLM、SIREN 和 CNN 三个模块，训练时则采用分阶段优化。第一阶段获得 FiLM 条件调制模块与 SIREN 残差表示模块的 E130 参数；第二阶段固定这两个模块及条件编码器，只优化 CNN 模块。CNN 输出卷积的权重和偏置初始化为零，因此第二阶段开始时 $\Delta\mathbf{r}_\theta$ 恒为零，完整 FSC 的初始函数与第一阶段模型一致。这里的零初始化仅针对 CNN 输出层，不是把整个 CNN 的权重全部置零，也不意味着初始输出等于 MCA。

训练总目标由归一化残差 SmoothL1 损失与七个辅助项组成：

$$\mathcal{L} = \mathcal{L}_{\text{res}} + \frac{1}{\sigma_r} (0.75\mathcal{L}_{\text{ERB-proxy}} + 0.25\mathcal{L}_{\text{contraHF}} + 0.75\mathcal{L}_{\text{strictILD}} + 0.05\mathcal{L}_{\text{bandILD}} + 0.25\mathcal{L}_{\Delta f} + 0.15\mathcal{L}_{\Delta^2 f} + 0.30\mathcal{L}_{\text{notch}}). \quad (8)$$

$\mathcal{L}_{\text{res}}$ 的 SmoothL1 阈值为归一化单位下的 1。其他项按实现除以训练残差标准差 σ_r ，并在各自方向子集内重新归一化固体角权重，再对耳侧及相应频点或频带平均。

ERB 代理项是复合目标中的核心频谱项，在 50–20000 Hz 对应的 ERB 轴上均匀设置 41 个中心，用三角权重对选定频点的线性功率积分，再比较频带能量的 dB 差。该设计意在使训练优化更贴近本文重点关注的听觉频带误差，而最终结论仍以严格 HRIR 域 ERB 评价为准。 $\mathcal{L}_{\text{contraHF}}$ 为对侧半空间中高于 10 kHz 频点的幅度绝对误差。两个项分别约束频带能量和高频绝对幅度，但前者不是最终报告的严格 HRIR 域 ERB 评价。

局部频谱结构项使用 4 kHz 及以上的相邻频点差分。记幅度误差序列 $\epsilon_f = \widehat{M}_f - M_f^*$ ，一阶和二阶项分别平均 $|\epsilon_{f+1} - \epsilon_f|$ 与 $|\epsilon_{f+2} - 2\epsilon_{f+1} + \epsilon_f|$ 。差分模板全部频点都须位于所选频段，其单位分别记为 dB/bin 和 dB/bin²，不写成对连续频率的导数。多尺度谱凹口项比较

$$D_r(M)_f = \tau \log \left[1 + \exp \left(\frac{(M_{f-r} + M_{f+r})/2 - M_f - \eta}{\tau} \right) \right], \quad (9)$$

其中半径 $r \in \{4, 8, 16\}$ 个频点，中心频率位于 4–18 kHz， $\eta = 1$ dB、 $\tau = 0.5$ dB；对各半径的深度图绝对差求均值。

双耳项在独立水平面采样上计算。严格耳间声级差（Interaural Level Difference, ILD）损失使用重建 HRIR 的左右耳能量比，频带 ILD 损失则使用中心频率 200–18000 Hz 内的 ERB 代理频带左右耳功率差，并采用阈值 0.5 dB 的 SmoothL1。使用独立采样保证每步都有水平面方向参与双耳项；这些约束不构成各项测试误差必然下降的保证。

每个训练轮次遍历 262 名训练被试，每名被试执行一次参数更新，并分别从全测量域和独立水平面中不放回抽取 16 个插值方向。优化器采用 AdamW，学习率与权重衰减均为 10^{-4} ，梯度裁剪阈值为 5，使用 FP32 训练。学习率在前 2 轮线性预热，随后按 200 轮总计划进行余弦衰减。

第二阶段的正式训练预算固定为 190 轮（E190）。开发阶段三个随机种子的验证最优轮次分别为 190、190 和 170，因此按预先设定的中位数规则将 190 轮作为统一训练预算。三个正式成员分别载入对应的 E130 FiLM-SIREN 参数并重新初始化 CNN，随机种子为 20260821、20260822 和 20260823；最终统一取第 190 轮末点参数，并按式(7)进行等权集成。

4 实验设置

4.1 数据集与评价协议

实验使用 SONICOM 测量 HRTF 数据 [1]，并以空间声学定向格式（Spatially Oriented Format for Acoustics, SOFA）保存 [14]。所用文件变体为 `FreeFieldCompMinPhase_44kHz`，

采样率 44.1 kHz，每个被试包含 793 个方向的双耳 256 点 HRIR。这里的“MinPhase”对应自由场补偿文件命名，并不表示本文将完整 HRTF 约束为最小相位。SONICOM 原始论文描述的是较早的 120 人发布版本；本研究依据后续官方元数据快照及异常记录筛选可用数据，共得到 350 名被试。

被试按自由场均衡文件分层，并以固定种子 20260731 划分为 262 名训练、44 名验证和 44 名测试被试，同一被试不跨集合。归一化统计仅由训练数据计算。表 1 列出主要设置。参考方向的仰角范围为 -45° 至 90° ，因此本文的“全域”指数据实际提供的测量域，不包括缺失的下方球冠。

表 1: 数据与正式操作点

Tab. 1: Data and the fixed operating point

项目	设置
被试划分	训练 262 / 验证 44 / 测试 44
稀疏观测	Q26, 左右对称; 观测方向不计入插值评价
参考及评价方向	793 个参考方向; 767 个非观测方向; 其中 72 个水平面方向
学习频点	463 点, 86.1328125–19982.8125 Hz
时域重建	1024 点 IFFT 后保留 256 点 HRIR, 采样率 44.1 kHz
正式主模型	FSC, 三个 E190 末点成员, dB 残差等权集成

Q26 是在已有测量网格上构造的 26 方向子集，不视作精确 Lebedev 网格。选择过程固定北极与一个中矢状面方向，再选择 12 对左右对称方向，以扩大最小大圆间距，并用正则化三阶球谐设计的对数行列式处理并列。观测方向从评价中排除，所有学习方法只使用相应稀疏输入提供的个体信息。

模型结构、训练目标和正式训练预算均在训练 / 验证阶段确定，随后冻结三个 FSC 成员及其等权集成。需要说明的是，该测试划分在项目早期工程评估中已被使用，本文围绕 FSC 组织主要叙事的决定发生在部分测试结果已知之后。因此，本文将测试结果视为同一固定队列上的回顾性方法比较，不将其表述为完全独立的确认性实验，也不依据本文结果重新调整模型参数。

4.2 对比方法

主比较包含七个外部方法与本文 FSC: SH only、SUpDEq SH、SUpDEq Natural Neighbor、SUpDEq Barycentric、MCA、FSP-AE 和 RANF 构成外部方法集合。结果叙述首先检验相对 MCA 的残差补偿效果，再比较外部学习方法。

传统重建采用既有 SUpDEq / MCA 实现；球谐（Spherical Harmonics, SH）相关设置为三阶，头半径 0.09 m，所用 SH 正则参数为 0.01，自然邻域和重心插值保持各自冻结定义。主比较中的八个方法使用相同测试被试、Q26 观测和插值评价掩码，但不强行改写为相同的训练或推断机制。

对于 FSC 这类仅预测 MCA 幅度残差的方法，评价时采用第 3 节所述的 MCA 相位与未预测频点复用链路；对于直接生成 HRIR 的方法，则保留其原生输出，并映射到统一的评价表示与频点。八种方法使用同一测试被试、Q26 观测集合与评价掩码，最终均在完整重建结果上计算本文定义的 12 项报告指标。比较基于冻结预测完成，不依据本文结果重新训练或调参。

4.3 评价指标

本文正文重点报告五项指标，数值均为越低越好。全域 ERB 误差（FullSphereERB）将重建和参考 HRIR 输入 `AKerbError`，分析范围为 50 Hz 至奈奎斯特频率 22.05 kHz，对频带绝对误差及双耳平均，并对 767 个插值方向按固体角加权。对侧 25° ERB 误差（Contralateral25ERB）沿用相同 HRIR 域误差，分别限制在左耳对侧中心 (270°, 0°)、右耳对侧中心 (90°, 0°) 的大圆半径 25° 区域，并在每个区域重新归一化方向权重。本文将这两项严格 HRIR 域 ERB 误差作为核心评价指标，以对应空间听觉相关的频带能量偏差；它们与式(8)中的 ERB 代理目标定义不同。频带 ILD（ERBBandILDMean）在 72 个水平面插值方向上计算 200–18000 Hz 内 35 个代理 ERB 频带的左右耳能量差误差，并对方向及频带取平均。

耳间时间差（Interaural Time Difference, ITD）沿用 FSP-AE 公开流程的兼容实现 [6]：重建与参考 HRIR 均先进行 1.6 kHz 低通，以 384 kHz 重采样后在 ±1 ms 范围内通过互相关峰估计 ITD，不在峰值索引后继续插值。ITD 加权平均绝对误差（ITDWeightedMAE）对 767 个插值方向的绝对差按固体角加权，以 μs 计。第五项为全域对数谱失真（FullSphereLSD）：先在频率维计算重建与参考对数幅度差的均方根，再对双耳平均，并对 767 个插值方向按固体角加权。

七项补充指标用于描述另一评价域下的宽带谱误差、局部频谱结构和双耳关系。LAP 2024 兼容 LSD（LAP2024LSD）在全部 793 个方向上计算，包含 Q26 观测方向且不使用固体角加权，因此仅在补充材料中报告。ITD 最大绝对误差使用与正文 ITD 加权 MAE 相同的逐方向 ITD 估计，并在 767 个插值方向上取绝对误差最大值。对侧高频幅度误差（ContralateralHighFrequency）统计对侧半空间内高于 10 kHz 且不超过 20 kHz 的选定频点幅度绝对误差，方向按固体角加权，双耳分别归一化后平均。水平面 ILD 平均绝对误差（HorizontalILDMAE）采用

$$\text{ILD}(\mathbf{q}) = 10 \log_{10} \frac{\sum_{n=0}^{255} |h_L(\mathbf{q}, n)|^2}{\sum_{n=0}^{255} |h_R(\mathbf{q}, n)|^2}, \tag{10}$$

并在 72 个水平面插值方向上算术平均预测与参考 ILD 的绝对差。该指标基于完整 HRIR 的宽带能量比，与主要指标中的频带 ILD 定义不同，二者不能互相替代。高频一阶与二阶差分误差在 4 kHz 以上比较相邻频点变化，多尺度凹口深度误差则在 4–18 kHz 内使用半径 4、8 和 16 个频点的局部深度图；三者均在 767 个插值方向上按固体角加权。

表 2：十二项报告指标的分层

Tab. 2: Hierarchy of the twelve reported metrics		
层级	内容	数量
正文	全域 ERB、对侧 25° ERB、频带 ILD、ITD 加权 MAE、全域 LSD	5
补充	LAP 2024 LSD、ITD 最大绝对误差、对侧高频幅度误差、水平面 ILD 误差、高频一 / 二阶差分、多尺度凹口深度	7

十二项指标并非相互独立，本文不通过跨量纲相加或胜出项计数构造总分。

统计独立单位为被试。所有方法均以 44 名测试被试为统计样本，方向和频点不作为独立样本扩充样本量，三个集成成员也不视为独立测试样本。正文首先报告各方法的均值 ± 样本标准差，以保持方法间绝对误差比较的直观性。已有 FSC 中心被试级 paired bootstrap 归档覆盖全域 ERB、对侧 25° ERB、频带 ILD、ITD 加权 MAE 以及补充材料中的 LAP 2024 LSD：

对 MCA、FSP-AE 和 RANF 进行 10000 次重采样，差值统一定义为 $\Delta = E_{\text{FSC}} - E_{\text{baseline}}$ ，负值表示 FSC 误差更低。完整配对差及 95% 区间作为补充材料给出，不用于替代正文的绝对指标表；全域 LSD 在正文中保持绝对误差比较。所有测试被试均保留，不按误差剔除个体。

4.4 实现与开发设置

FiLM-SIREN 结构参数通过训练 / 验证阶段的分阶段搜索确定。SIREN 部分依次比较频率映射、首层频率系数、网络深度与宽度，最终采用线性 / ERB 双频率坐标、6 层、隐藏宽度 256 以及 $\omega = 20$ 。FiLM 部分比较条件维度、调制形式、调制层位置以及全局 / 局部 MCA 输入，最终采用 128 维个体条件、全调制并作用于全部正弦层。上述搜索用于确定可复现的正式配置，不声称获得全局最优超参数。

组件比较在 44 名验证被试上进行：一侧为三个 FiLM-SIREN E130 成员的等权集成，另一侧为在其基础上继续进行第二阶段训练的三个完整 FSC E190 成员。由于该比较同时改变双耳频谱 CNN、额外优化预算和复合损失，因此仅用于评估完整训练链路的增量效果，不作为单一 CNN 模块的严格消融。

稀疏度实验采用嵌套集合 $Q14 \subset Q26 \subset Q50$ ，并对每个观测密度使用 matched-density 训练：Q14 和 Q50 分别从 current-Q MCA 残差重新构建训练数据，独立训练 FiLM-SIREN E130 及冻结骨干后的频谱 CNN E190，并使用与 Q26 相同的三随机种子等权集成；Q26 直接复用正式冻结 ensemble。训练完成并冻结模型后，三种密度统一在 44 名测试被试上评价。为保证不同观测密度具有完全一致的评价方向，从 793 方向网格中统一排除 Q50 包含的 50 个观测方向，以剩余 743 个方向作为公共测试集合。因此，本节 Q26 与前文正式 Q26 比较使用相同模型，但评价方向集合不同；前文 Q26 在其自身 767 个未观测方向上评价，而本节采用共同 743 方向，局部空间指标尤其可能因此出现较明显的数值差异。该设置使表中变化主要反映 matched-density 条件下观测方向数量的影响，而非固定 Q26 模型的输入失配。

5 结果

本节首先分析 FSC 相对 MCA 的残差补偿效果，随后比较学习式方法，并补充其余双耳 / 局部频谱、组件增量和 matched-density 稀疏度结果。主方法比较与 matched-density 稀疏度实验均使用 44 名测试被试；组件比较仍仅使用 44 名验证被试。正文以均值和样本标准差为主，已有 FSC 中心配对 bootstrap 归档另列于补充材料。

5.1 与 MCA 对比

FSC 相对 MCA 的五项正文指标呈现较明确的频谱收益与较弱的时间线索变化。表 3 中，全域 ERB 从 1.0822 降至 0.8175 dB，对侧 25° ERB 从 1.7458 降至 1.2004 dB，频带 ILD 从 2.0562 降至 1.6205 dB；ITD 加权 MAE 仅由 18.3997 降至 18.0457 μs 。全域 LSD 由 4.7914 降至 3.5729 dB，说明 FSC 相对 MCA 的宽带对数幅度谱误差也明显降低。

FSC 中心的被试级配对 bootstrap 统计见补充材料。其作用是检验同一 44 名被试上的方法差异稳定性，而正文表格仍以各方法绝对误差的均值 $\pm$ 样本标准差作为主要展示。已有归档显示，FSC 相对 MCA 的全域 ERB、对侧 25° ERB 和频带 ILD 配对差区间均位于

表 3: FSC 与传统插值方法五项正文指标 (44 名测试被试, Q26)

Tab. 3: Five main-text metrics of FSC and conventional interpolation methods (44 test subjects, Q26)

方法	全域 ERB dB↓	对侧 25° ERB dB↓	频带 ILD dB↓	ITD 加权 MAE μ s↓	全域 LSD dB↓
FSC	0.8175 $\pm$ 0.3427	1.2004 $\pm$ 0.0952	1.6205 $\pm$ 0.6772	18.0457 $\pm$ 16.7629	3.5729 $\pm$ 0.5722
SH only	2.6854 $\pm$ 0.1072	3.8353 $\pm$ 0.4484	4.5959 $\pm$ 0.3878	50.3170 $\pm$ 6.3786	7.9251 $\pm$ 0.2617
SUpDEq SH	1.8821 $\pm$ 0.5060	2.2281 $\pm$ 0.1947	2.9904 $\pm$ 1.0775	15.9970 $\pm$ 14.3296	6.4271 $\pm$ 0.9548
SUpDEq NN	1.8518 $\pm$ 0.2901	2.2405 $\pm$ 0.2123	2.5197 $\pm$ 0.2597	15.1371 $\pm$ 11.9612	5.8587 $\pm$ 0.3787
SUpDEq Bary.	1.7522 $\pm$ 0.2567	2.1821 $\pm$ 0.1929	2.5630 $\pm$ 0.2635	15.4321 $\pm$ 11.3719	5.7190 $\pm$ 0.3428
MCA	1.0822 $\pm$ 0.0959	1.7458 $\pm$ 0.1551	2.0562 $\pm$ 0.1948	18.3997 $\pm$ 15.6546	4.7914 $\pm$ 0.2712

数值为被试均值 $\pm$ 样本标准差, 加粗表示本表最低均值。五项指标均在 Q26 的 767 个未观测方向评价; 全域 ERB、对侧 ERB 与全域 LSD 使用固体角加权, 频带 ILD 使用 72 个水平面插值方向, ITD 加权 MAE 按 767 方向固体角加权。

零以下; ITD 加权 MAE 区间跨越零, 因此本文不将其解释为稳定的时间线索改善。LAP 2024 LSD 的描述性比较与配对结果一并移至补充材料。

5.2 与学习方法对比

表 4 单独比较 FSC、RANF 和 FSP-AE。FSC 的全域 ERB、对侧 25° ERB、频带 ILD 和 ITD 加权 MAE 均值最低; 全域 LSD 则由 FSP-AE 最低, RANF 次之, FSC 排名第三。

表 4: FSC 与学习式方法五项正文指标 (44 名测试被试, Q26)

Tab. 4: Five main-text metrics of FSC and learning-based methods (44 test subjects, Q26)

方法	全域 ERB dB↓	对侧 25° ERB dB↓	频带 ILD dB↓	ITD 加权 MAE μ s↓	全域 LSD dB↓
FSC	0.8175 $\pm$ 0.3427	1.2004 $\pm$ 0.0952	1.6205 $\pm$ 0.6772	18.0457 $\pm$ 16.7629	3.5729 $\pm$ 0.5722
RANF	1.0632 $\pm$ 0.1264	1.5573 $\pm$ 0.1636	1.7360 $\pm$ 0.2220	23.5840 $\pm$ 34.9663	3.3736 $\pm$ 0.2692
FSP-AE	1.1845 $\pm$ 0.3492	1.9089 $\pm$ 0.7008	1.6994 $\pm$ 0.6925	18.3583 $\pm$ 16.0409	3.1202 $\pm$ 0.5763

数值为被试均值 $\pm$ 样本标准差, 加粗表示本表最低均值。FSC 中心的被试级配对 bootstrap 统计作为补充材料提供; 现有配对归档覆盖前四项正文指标及 LAP 2024 LSD。

三种学习方法在不同指标上的优势并不一致。因此, 本文将 FSC 定位为在 ERB、频带 ILD 和 ITD 加权 MAE 上具有较低均值、但在全域 LSD 上仍落后于 FSP-AE 与 RANF 的残差细化方案, 而非替代全部方法的无代价最优解。

5.3 次要指标分析

正文之外的双耳与局部频谱指标进一步揭示不同误差类型之间的取舍 (表 5)。FSP-AE 在对侧高频、水平面 ILD 和 ITD 最大绝对误差上的均值最低, 分别为 3.1644 dB、0.7587 dB 和 123.6387 μ s; FSC 对应为 3.4549 dB、0.7794 dB 和 151.2784 μ s。另一方面, FSC 在高频一阶差分、二阶差分和多尺度凹口深度上的均值最低, 分别为 0.3997 dB/bin、0.2146 dB/bin² 和 0.4877 dB。这表明局部谱形改善与宽带双耳 / 极端 ITD 误差优势可以由不同方法获得。

这些指标均用于补充描述, 不由其客观误差直接推出感知定位改善。

表 5: 其余双耳指标与局部频谱指标 (44 名测试被试, Q26)

Tab. 5: Other binaural and local-spectral metrics (44 test subjects, Q26)

方法	对侧高频 dB↓	水平面 ILD dB↓	ITD 最大误差 μs ↓	高频一阶差分 dB/bin↓	高频二阶差分 dB/bin ² ↓	凹口深度 dB↓
SH only	9.0669	3.5511	280.2438	0.6135	0.2990	0.8679
SUpDEq SH	5.9936	2.0181	143.8210	0.6163	0.3230	0.8034
SUpDEq NN	5.5954	1.6370	144.7088	0.5769	0.3106	0.7399
SUpDEq Bary.	5.4756	1.6151	145.1823	0.5765	0.3092	0.7411
MCA	4.6986	0.8294	141.3944	0.6033	0.3231	0.7778
FSP-AE	3.1644	0.7587	123.6387	0.4050	0.2153	0.4987
RANF	3.4697	0.7755	195.4309	0.4051	0.2172	0.4893
FSC	3.4549	0.7794	151.2784	0.3997	0.2146	0.4877

均为被试均值, 加粗仅表示本表八种方法中的最低均值。对侧高频及三项局部频谱指标使用 767 个插值方向, 水平面 ILD 使用 72 个水平面插值方向; ITD 最大误差使用与正文 ITD 加权 MAE 相同的逐方向 ITD 估计后取最大绝对误差。LAP 2024 LSD 移至补充材料。

5.4 组件比较

本节报告验证集上的组件增量比较。由于完整 FSC 相对 FiLM-SIREN 配置同时引入双耳频谱 CNN、第二阶段优化和复合目标, 该实验不属于严格的单因素消融, 结果仅用于刻画完整训练链路带来的增量变化。

在同一 44 名验证被试及 767 方向上, 完整 FSC 相对不含 CNN 模块的 FiLM-SIREN E130 集成, 在开发阶段归档的五个端点上均值均降低 (表 6)。全域 ERB、对侧 25° ERB 和频带 ILD 分别降低 0.023122、0.016183 和 0.074668 dB; ITD 加权 MAE 和最大绝对误差分别仅降低 0.020803 和 0.118373 μs 。该结果说明第二阶段完整训练链路对幅度频谱指标有稳定的开发趋势, 但由于 CNN、训练预算和复合目标同时变化, 不能将收益单独归因于 CNN 结构, 极小的 ITD 均值差也不应解释为稳定时间线索改善。

表 6: FiLM-SIREN 与 FSC 的五个开发阶段归档端点比较 (44 名被试, 767 方向)

Tab. 6: Validation comparison of FiLM-SIREN and FSC on five archived development endpoints (44 subjects, 767 directions)

指标 ↓	FiLM-SIREN E130	FSC E190
全域 ERB	0.8275 ± 0.1602	0.8044 ± 0.1614
对侧 25° ERB	1.2308 ± 0.1878	1.2146 ± 0.1887
频带 ILD	1.5739 ± 0.1653	1.4992 ± 0.1523
ITD 加权 MAE (μs)	15.5432 ± 2.3330	15.5224 ± 2.3298
ITD 最大绝对误差 (μs)	130.3267 ± 39.6414	130.2083 ± 39.3381

数值为被试均值 ± 样本标准差, 两种模型均为三个成员的等权集成。两项 ERB 来自既有验证归档; 频带 ILD 和两项 ITD 来自同一被试、方向域及冻结预测的补充验证归档。该表用于描述第二阶段完整训练链路的增量变化, 不作为正文五项测试指标的替代。

两侧都是三成员集成, 差异不仅包含是否使用 CNN 模块, 还包含第二阶段优化与复合目标。频带 ILD 和两项 ITD 来自同一被试、方向域及冻结预测; 该比较属于开发阶段证据, 不是对 CNN 结构、各损失项或集成效应的逐项因果隔离, 也不与测试集均值混合报告。

5.5 Matched-density 稀疏度实验

在 Q14、Q26 和 Q50 三种观测密度下分别训练对应 FSC 模型后，在 44 名测试被试及共同 743 个未观测方向上的结果如表 7 所示。除 ITD 加权 MAE 外，其余五项指标的平均误差均随观测方向数增加而持续下降。全域 ERB 由 Q14 的 0.9340 ± 0.4673 dB 降至 Q26 的 0.8132 ± 0.3410 dB，并在 Q50 进一步降至 0.7702 ± 0.3613 dB；对侧 25° ERB 也由 0.9136 ± 0.4553 dB 依次降至 0.8378 ± 0.3359 和 0.7970 ± 0.3835 dB。该结果表明，在 matched-density 训练条件下，增加观测方向总体有利于全域及对侧局部的 ERB 重建。

表 7: FSC matched-density 稀疏度实验 (44 名测试被试，共同 743 方向)

Tab. 7: Matched-density FSC sparsity experiment (44 test subjects, 743 shared directions)

观测密度	全域 ERB dB↓	对侧 25° ERB dB↓	频带 ILD dB↓	ITD 加权 MAE μ s↓	对侧高频 dB↓	水平面 ILD dB↓
Q14	0.9340 ± 0.4673	0.9136 ± 0.4553	1.6796 ± 0.8085	24.3936 ± 30.4457	3.6514 ± 0.3891	0.8106 ± 1.0585
Q26	0.8132 ± 0.3410	0.8378 ± 0.3359	1.6104 ± 0.6569	17.9106 ± 16.7770	3.4448 ± 0.2591	0.7719 ± 0.8157
Q50	0.7702 ± 0.3613	0.7970 ± 0.3835	1.5048 ± 0.6658	18.3552 ± 21.4477	3.3960 ± 0.2753	0.7046 ± 0.7751

数值为被试均值 $\pm$ 样本标准差。Q14、Q26、Q50 分别使用对应观测密度训练并冻结的 FSC 模型；三者采用相同网络结构、训练预算和三随机种子集成，并统一在排除 Q50 观测后的 743 个公共方向上评价 44 名测试被试。加粗表示三种密度中的最低均值。

其余指标呈现类似趋势：频带 ILD 从 Q14 的 1.6796 dB 降至 Q26 的 1.6104 dB，并在 Q50 进一步降至 1.5048 dB；对侧高频幅度误差从 3.6514 降至 3.4448 和 3.3960 dB，水平面 ILD 误差从 0.8106 降至 0.7719 和 0.7046 dB。ITD 加权 MAE 由 Q14 的 24.3936μ s 下降至 Q26 的 17.9106μ s，Q50 为 18.3552μ s，与 Q26 基本处于同一水平，说明进一步增加观测方向对该时间差指标的收益趋于饱和。总体而言，更多观测能够稳定改善 FSC 的幅度谱和双耳声级差相关指标，而 ITD 的主要收益在 Q26 附近已经获得。LAP 2024 LSD 的 matched-density 测试结果作为补充材料报告。

6 讨论

6.1 频谱细化与双耳线索的折衷

MCA 之后的残差学习在本研究中具有明确的幅度频谱补偿价值。表 3 显示，FSC 的全域 ERB、对侧 25° ERB、频带 ILD 和全域 LSD 均值均低于 MCA，而 ITD 加权 MAE 只小幅降低。相对学习式方法，FSC 在前三项及 ITD 加权 MAE 上具有较低均值，但 FSP-AE 和 RANF 的全域 LSD 更低。这说明 FSC 更擅长校正 MCA 残留的听觉频带与双耳声级误差，但宽带 LSD、时间线索和局部谱形并不会随 ERB 目标同步达到最优。本文因此不以领先项数量判定总体优劣。

局部谱形、双耳能量关系和 ITD 反映不同的重建要求。一、二阶差分及多尺度凹口深度约束局部频谱变化，绝对幅度误差和 ERB 误差则评价其他尺度的偏离。FSC 在三个局部端点上的最低均值，与 FSP-AE 的对侧高频和 ITD 最大绝对误差优势可以同时成立。这些局部端点与训练辅助项定义相近，其改善说明模型在所约束的目标上表现较好，但不足以证明一般听觉收益。全域 ERB 和频带 ILD 在外部主比较中的最低均值，也不能保证严格水平面 ILD 或 ITD 的稳定收益；前者基于完整重建 HRIR 的双耳能量比，后者通过低通互相关估计。FSC 不直接学习 ITD，联合输入双耳信息并设置 ILD 损失也不保证这些误差在每名被试上下降。

6.2 结构作用与模型复杂度

FSC 的 FiLM、SIREN 和 CNN 模块分别提供被试级条件、连续残差表示及跨频率双耳细化，并在同一前向链路中共同产生最终残差。与逐被试单独建模不同，条件编码器把每名被试的稀疏空间双耳观测压缩成共享维度的 embedding，使一个跨被试模型能够通过 FiLM 调制表达个体差异；这是本文结构设计中连接“个体声学观测”和“连续神经场”的关键接口。验证集组件比较中，完整 FSC 相对不含 CNN 模块的 FiLM-SIREN 配置在开发阶段归档的五个端点上均值下降，但 ITD 变化很小（表 6）。该观察支持三模块完整方案在幅度频谱端点上的开发趋势。由于比较同时涉及 CNN 模块、第二阶段优化和复合目标，尚不能把收益分别归因于卷积结构、某一损失项或集成。与训练目标一致的结构动机，应与已被隔离验证的机制区分。

CNN 输出层的零初始化仅保证第二阶段开始时完整 FSC 的函数等于第一阶段 FiLM-SIREN 配置，不保证训练后的误差单调下降。完整 FSC 推断始终包含 FiLM、SIREN、CNN 及三成员集成。Q26 正式模型中，单成员包含 1.519M 个部署参数，三成员集成为 4.557M；在 NVIDIA GeForce RTX 5060、FP32、793 方向 $\times 463$ 频点设置下，单成员模型推断中位数为 110.45 ms，三成员集成为 331.49 ms，后者端到端中位数为 513.24 ms（表 8）。该基准仅用于量化 FSC 自身开销，未在同一实现与硬件条件下测量全部基线，因此不据此提出跨方法效率优势。

表 8: FSC-Q26 模型规模与推断开销

Tab. 8: Model size and inference cost of FSC-Q26					
部署形式	参数量	Checkpoint	推断中位数	推断 P95	端到端中位数
	M	MiB	ms	ms	ms
单成员	1.519	6.45	110.45	110.95	—
三成员集成	4.557	19.35	331.49	332.10	513.24

在 NVIDIA GeForce RTX 5060、FP32 下，对一个验证被试的 793 方向 $\times 463$ 频点进行基准测试。模型推断统计含 5 次预热和 30 次计时，排除 checkpoint 加载与磁盘 I/O；端到端统计含输入读取和输出序列化。该结果仅描述 FSC 自身开销，不用于宣称相对其他方法的效率优势。

6.3 泛化范围与研究局限

新的 matched-density 测试实验表明，FSC 在 Q14、Q26、Q50 三个密度上能够通过独立训练利用更多观测信息；在 SONICOM 的 44 名测试被试及共同 743 方向上，除 ITD 加权 MAE 外，其余报告指标的平均误差均随观测密度增加而下降。ITD 从 Q14 到 Q26 明显改善，而 Q50 与 Q26 接近，提示额外测量对不同评价维度的边际收益并不一致。该结论仍限于单一 SONICOM 数据库，尚不能直接外推到其他数据库或不同空间采样方案。

本文的复合目标采用 ERB 代理作为核心频谱项，并联合高频误差、ILD、频谱差分 and 凹口深度等约束。其主要贡献在于给出一种面向稀疏 HRTF 残差细化的听觉频带导向目标设计思路，而不是将某一固定损失形式视为最终答案。后续可在此基础上研究与严格 HRIR 域 ERB 更一致的可微目标、自适应多目标平衡及感知损失。

此外，本文仍受到以下限制：数据仅来自单一数据库，因此跨数据库泛化尚未验证；FSC 复用 MCA 相位且不直接预测 ITD，因此时间线索能力受前端重建约束；三成员集成带来

约 4.56M 部署参数和额外推断开销，且尚未在统一实现与硬件条件下完成与全部基线的效率比较；组件比较同时改变 CNN、训练预算和复合目标，不能提供严格单因素因果归因；测试划分曾用于项目早期工程评估，论文主模型的确定发生在部分结果可见之后，因此测试结果属于回顾性比较而非完全独立确认；最后，当前没有主观听音实验，客观 ERB、ILD、ITD 或 LSD 改善不能直接等同于定位准确性、外化感或偏好的提升。

7 结论

本文提出一种基于 MCA 残差学习与条件隐式表示的稀疏 HRTF 插值方法 FSC，用于补偿 MCA 插值后仍存在的方向相关幅度残差。模型将每名被试的稀疏空间双耳观测压缩为固定维度 embedding，通过 FiLM 调制 SIREN 连续残差场，并利用双耳频谱 CNN 进一步修正跨频率结构；最终复用 MCA 相位完成 HRIR 重建。与此同时，本文将严格 HRIR 域 ERB 误差作为核心评价维度，并在训练中引入 ERB 代理目标，使学习重点集中于具有听觉频带意义的幅度误差。

在 SONICOM 的 Q26 测试协议下，FSC 的全域 ERB、对侧 25° ERB、频带 ILD、ITD 加权 MAE 和全域 LSD 分别为 0.8175、1.2004、1.6205 dB、18.0457 μ s 和 3.5729 dB。相对 MCA，FSC 在 ERB、频带 ILD 及全域 LSD 上均取得更低均值；相对 FSP-AE 和 RANF，FSC 在前三项及 ITD 加权 MAE 上更低，但全域 LSD 仍落后。进一步的 matched-density 测试实验表明，在共同 743 方向上，全域 ERB、对侧 25° ERB、频带 ILD、对侧高频和水平面 ILD 的平均误差均随 Q14、Q26、Q50 逐步下降；ITD 加权 MAE 则从 Q14 明显下降至 Q26，并在 Q50 保持相近水平，说明更多观测的收益具有评价维度依赖性。

当前方法仍受到单一数据库、MCA 相位依赖、三成员集成成本、非严格组件消融及缺少听音实验等限制。后续工作将重点研究更一致的 ERB / 感知目标、跨数据库泛化、严格消融和主观空间听觉验证。

参考文献

- [1] Engel I, Daugintis R, Vicente T, et al. The SONICOM HRTF dataset[J]. Journal of the Audio Engineering Society. 2023, 71(5):241–253. DOI: 10.17743/jaes.2022.0066.
- [2] Li S, Peissig J. Measurement of head-related transfer functions: A review[J]. Applied Sciences. 2020, 10(14):5014. DOI: 10.3390/app10145014.
- [3] Bruschi V, Grossi L, Dourou N A, et al. A review on head-related transfer function generation for spatial audio[J]. Applied Sciences. 2024, 14(23):11242. DOI: 10.3390/app142311242.
- [4] Pörschmann C, Arend J M, Brinkmann F. Directional equalization of sparse head-related transfer function sets for spatial upsampling[J]. IEEE/ACM Transactions on Audio, Speech, and Language Processing. 2019, 27(6):1060–1071. DOI: 10.1109/TASLP.2019.2908057.
- [5] Arend J M, Brinkmann F, Pörschmann C. Assessing spherical harmonics interpolation of time-aligned head-related transfer functions[J]. Journal of the Audio Engineering Society. 2021, 69(1/2):104–117. DOI: 10.17743/jaes.2020.0070.

- [6] Ito Y, Nakamura T, Koyama S, et al. Spatial upsampling of head-related transfer function using neural network conditioned on source position and frequency[J]. *IEEE Open Journal of Signal Processing*. 2025, 6:1109–1123. DOI: 10.1109/OJSP.2025.3613132.
- [7] Masuyama Y, Wichern G, Germain F G, et al. RANF: Neural field-based HRTF spatial upsampling with retrieval augmentation and parameter efficient fine-tuning[J]. *IEEE Open Journal of Signal Processing*. 2026, 7:32–41. DOI: 10.1109/OJSP.2025.3640517.
- [8] Arend J M, Pörschmann C, Weinzierl S, et al. Magnitude-corrected and time-aligned interpolation of head-related transfer functions[J]. *IEEE/ACM Transactions on Audio, Speech, and Language Processing*. 2023, 31:3783–3799. DOI: 10.1109/TASLP.2023.3313908.
- [9] Perez E, Strub F, de Vries H, et al. FiLM: Visual reasoning with a general conditioning layer[J]. *Proceedings of the AAAI Conference on Artificial Intelligence*. 2018, 32(1). DOI: 10.1609/aaai.v32i1.11671.
- [10] Sitzmann V, Martel J, Bergman A, et al. Implicit neural representations with periodic activation functions[C/OL]. *Advances in Neural Information Processing Systems: volume 33*. 2020. <https://proceedings.neurips.cc/paper/2020/hash/53c04118df112c13a8c34b38343b9c10-Abstract.html>.
- [11] Arend J M, Pörschmann C. Spatial upsampling of sparse head-related transfer function sets by directional equalization—influence of the spherical sampling scheme[C/OL]. *Proceedings of the 23rd International Congress on Acoustics*. 2019: 2643–2650. https://audiogroup.web.th-koeln.de/PUBLIKATIONEN/Arend_ICA2019.pdf.
- [12] Fantini D, Geronazzo M, Avanzini F, et al. A survey on machine learning techniques for head-related transfer function individualization[J]. *IEEE Open Journal of Signal Processing*. 2025, 6:30–56. DOI: 10.1109/OJSP.2025.3528330.
- [13] Rafaely B, Weinzierl S, Berebi O, et al. Loss Functions Incorporating Auditory Spatial Perception in Deep Learning—A Review[M/OL]. 2025. <https://arxiv.org/abs/2506.19404v1>. DOI: 10.48550/arXiv.2506.19404.
- [14] Majdak P, Zotter F, Brinkmann F, et al. Spatially oriented format for acoustics 2.1: Introduction and recent advances[J]. *Journal of the Audio Engineering Society*. 2022, 70(7/8):565–584. DOI: 10.17743/jaes.2022.0026.

Sparse HRTF Interpolation via MCA Residual Learning and Conditional Implicit Representation

Young

Abstract: Sparse head-related transfer function (HRTF) interpolation can leave substantial direction-dependent magnitude residuals. This paper proposes FSC, a sparse HRTF interpolation method based on MCA residual learning and conditional implicit representation, combining feature-wise linear modulation (FiLM), a sinusoidal representation network (SIREN), and a binaural spectral CNN. Sparse binaural spatial observations of each subject are compressed into a fixed-dimensional subject embedding, which conditions the shared SIREN residual field through FiLM. The model further refines cross-frequency binaural structure while reusing the phase of magnitude-corrected and time-aligned interpolation (MCA). Equivalent rectangular bandwidth (ERB) error is treated as a central evaluation dimension, with an ERB-oriented proxy included in the training objective. On 44 SONICOM test subjects under Q26, FSC achieved full-sphere ERB, contralateral-25° ERB, ERB-band ILD, weighted ITD MAE, and full-sphere LSD values of 0.8175, 1.2004, 1.6205 dB, 18.0457 μ s, and 3.5729 dB, respectively. FSC improved the three magnitude/level metrics and full-sphere LSD over MCA, while FSP-AE and RANF remained better on full-sphere LSD. In matched-density experiments with separately trained Q14, Q26, and Q50 models evaluated on 44 test subjects over a common 743-direction domain, full-sphere ERB decreased from 0.9340 to 0.8132 and 0.7702 dB, while contralateral-25° ERB decreased from 0.9136 to 0.8378 and 0.7970 dB. These results support MCA residual learning with subject-conditioned implicit representation for sparse HRTF interpolation, while temporal cues, cross-dataset generalization, and perceptual benefits remain open.

Key Words: head-related transfer function; HRTF interpolation; MCA; residual learning; conditional implicit representation; interaural cues